



MCDI500 - Programación para la Ciencia de Datos

20/09/2026

PROYECTO ENSSEX

Dependencia económica y bienestar en personas que conviven con su pareja
Avance de las fases 1 y 2

Repositorio: <https://github.com/gosoriozamora/mcdi500-grupo9-enssex>

Integrantes Grupo 9

Karla Pizarro Correa

Guillermo Osorio Zamora

Docente

Omar Salinas Silva

Contenido

1. Introducción y contextualización.....	3
2. Definición de la problemática y objetivos del proyecto	5
2.1 Pregunta de investigación	5
2.2 Objetivo general	5
2.3 Objetivos específicos	5
2.4 Alcance, restricciones y supuestos	6
3. Aplicación de herramientas científicas y reproducibilidad técnica	8
3.1 Herramientas científicas utilizadas	8
3.2 Entorno reproducible y dependencias	8
3.3 Control de versiones y repositorio GitHub	10
3.4 Documentación y trazabilidad del proceso	12
4. Diseño de la solución y procesamiento de datos	14
4.1 Codificación funcional	14
4.2 Preprocesamiento y transformación del dataset	15
4.3 Validación técnica y verificación	18
5. Notebook F1 de definición del proyecto	21
5.1 Contenido y alcance	21
5.2 Ejecución y evidencias	21
6. Notebook F2 de limpieza y transformación	22
6.1 Organización del cuaderno	22
6.2 Ejecución y resultados	22
6.3 Archivos que recibe la fase siguiente	22
7. Vinculación del mapa conceptual con el avance	23
8. Conclusiones del avance F1 y F2	26
9. Bibliografía	27

1. Introducción y contextualización

La Encuesta Nacional de Salud, Sexualidad y Género (ENSSEX) 2022–2023 fue desarrollada por el Ministerio de Salud para conocer distintas dimensiones de la salud sexual y reproductiva y aportar evidencia para las políticas públicas. Retoma como antecedente el estudio nacional realizado en 1998. Su población objetivo corresponde a personas de 18 años y más residentes en comunas urbanas de las dieciséis regiones de Chile. El archivo utilizado en este proyecto contiene 20.392 registros y 1.126 columnas. La representatividad del diseño de la encuesta debe distinguirse del alcance de nuestro análisis, que describe a las personas seleccionadas en la muestra sin aplicar factores de expansión (Ministerio de Salud, 2022).

La base se obtuvo desde el Portal de Datos Abiertos del Estado. Se conserva el SAV original y una conversión íntegra a CSV; la fuente y su licencia Creative Commons CCZero (CC0) están registradas en la documentación de obtención del proyecto (Ministerio de Salud, s. f.-b).

La amplitud temática de la encuesta permite abordar también dimensiones vinculadas con el bienestar, las relaciones de pareja y las condiciones sociales y económicas de las personas. En este contexto, el presente proyecto se concentra específicamente en las personas encuestadas que conviven actualmente con su pareja y busca analizar conjuntamente tres dimensiones:

- la valoración de la vida sexual
- el bienestar mental o emocional percibido
- el grado de dependencia económica respecto de la pareja.

El propio conjunto de datos dispone de variables que permiten identificar la convivencia con la pareja y consultar directamente si la persona depende económicamente de ella.

A partir de estas dimensiones, la pregunta que orienta el proyecto es: ¿Cómo varían la valoración de la vida sexual y el bienestar mental o emocional percibido según el grado de dependencia económica respecto de la pareja entre las personas encuestadas en ENSSEX 2022–2023 que conviven con ella?

El objetivo general del proyecto es analizar cómo varían la valoración de la vida sexual y el bienestar mental o emocional percibido según el grado de dependencia económica de la pareja en personas encuestadas en ENSSEX 2022–2023 que conviven con ella.

El estudio tiene un alcance descriptivo y comparativo de la muestra seleccionada. Busca identificar diferencias y patrones entre grupos de dependencia económica, sin establecer relaciones causales ni extrapolar los resultados a la población chilena.

El volumen y la estructura de ENSSEX requieren seleccionar sistemáticamente la población de interés, interpretar los códigos de respuesta, revisar la calidad de las variables y comprobar cada transformación. Python, pandas y NumPy permiten automatizar estas operaciones, mientras que Jupyter reúne las explicaciones, el código y sus resultados. Git y GitHub registran los cambios y facilitan la revisión del trabajo. Este informe documenta la definición del proyecto y la preparación de una base analítica verificable; la comparación sustantiva de las valoraciones se desarrollará en las fases siguientes.

El proyecto se desarrolla progresivamente a través de cuatro fases articuladas.

- En la Fase 1 se delimita la problemática, se establecen los objetivos y se configura el entorno reproducible de trabajo.
- En la Fase 2 se realiza la obtención, exploración, limpieza, transformación y validación del conjunto de datos, generando una base procesada y técnicamente preparada para las etapas posteriores.
- En la Fase 3, el trabajo avanza hacia el diseño e implementación de una solución en Python con una estructura escalable, modular y reutilizable, incorporando clases, atributos, métodos y principios de programación orientada a objetos, como herencia, polimorfismo y encapsulamiento.
- Finalmente, la Fase 4 corresponde al cierre integrador del proyecto, en el que se consolidan y validan los resultados obtenidos, se revisa la coherencia metodológica del proceso y se comunican profesionalmente los hallazgos, conclusiones y decisiones adoptadas mediante un informe técnico y una presentación final.

El presente informe documenta el avance implementado en F1 y F2 y sus evidencias de ejecución. F3 y F4 permanecen como etapas de desarrollo posterior, de acuerdo con el carácter progresivo del proyecto y el alcance de la Sumativa 1 (Universidad Andrés Bello, s. f.).

2. Definición de la problemática y objetivos del proyecto

El fenómeno analizado corresponde a las posibles diferencias en la valoración de la vida sexual y en el bienestar mental o emocional percibido entre personas que conviven con su pareja, considerando su grado de dependencia económica respecto de ella. El interés del proyecto se centra en determinar si estas dimensiones de bienestar presentan comportamientos distintos entre los grupos definidos según su nivel de dependencia económica, utilizando la información disponible en la Encuesta Nacional de Salud, Sexualidad y Género (ENSSEX) 2022–2023.

La población de análisis quedó delimitada a las personas que declararon tener pareja y convivir actualmente con ella. En este grupo resulta pertinente comparar la dependencia económica declarada con las dos dimensiones de bienestar seleccionadas. F1 estableció esta definición y F2 preparó los datos necesarios para las comparaciones posteriores.

2.1 Pregunta de investigación

La pregunta escogida para investigación corresponde a:

¿Cómo varían la valoración de la vida sexual y el bienestar mental o emocional percibido según el grado de dependencia económica de la pareja entre las personas encuestadas en ENSSEX 2022–2023 que conviven con ella?

Nos interesa conocer si las respuestas sobre estos dos ámbitos del bienestar presentan diferencias entre quienes dependen completamente de su pareja, quienes dependen en parte y quienes declaran no depender económicamente de ella. La pregunta se centra en personas que comparten su vida cotidiana con una pareja y utiliza información que está disponible en la encuesta.

2.2 Objetivo general

Analizar cómo varían la valoración de la vida sexual y el bienestar mental o emocional percibido según el grado de dependencia económica de la pareja en personas encuestadas en ENSSEX 2022–2023 que conviven con ella.

2.3 Objetivos específicos

- a) Identificar a las personas encuestadas que declaran convivir con su pareja y conformar con ellas la población de análisis.
- b) Describir la distribución del grado de dependencia económica de la pareja en la población seleccionada.
- c) Caracterizar la valoración de la vida sexual y el bienestar mental o emocional percibido según los distintos grados de dependencia económica.
- d) Comparar ambas dimensiones de bienestar entre los grupos definidos por nivel de dependencia económica, identificando diferencias y patrones relevantes.

2.4 Alcance, restricciones y supuestos

Alcance del proyecto

El análisis se centra en las 8.579 personas de ENSSEX 2022–2023 que declaran tener pareja y convivir con ella. La selección se realizó mediante la aplicación conjunta de «Tiene pareja actualmente» (p81=1) y «Convive actualmente con su pareja» (p83=1). Esta cifra describe los registros seleccionados en la muestra, no una estimación de la cantidad de personas convivientes en Chile.

La selección considera 19 columnas originales: 3 variables centrales, 12 complementarias y 4 auxiliares. El estudio tendrá como eje las siguientes tres variables centrales:

- El grado de dependencia económica respecto de la pareja (p93), variable explicativa ordinal.
- La valoración de la vida sexual (i_6_p9), variable de resultado ordinal.
- El bienestar emocional percibido (i_2_p9), variable de resultado ordinal.

El propósito será caracterizar y comparar ambas dimensiones de bienestar entre los distintos niveles de dependencia económica. Compararemos por separado las respuestas sobre vida sexual y bienestar mental o emocional. Aunque ambas utilizan una escala de 1 a 7, representan ámbitos distintos y no las sumaremos para construir un único indicador.

Las tres variables centrales y los dos filtros de pareja y convivencia permiten abordar la pregunta básica. Las complementarias aportan contexto sociodemográfico, de relación y de salud; el folio y la fecha cumplen funciones técnicas. Esta selección no implica que las 19 columnas deban utilizarse juntas en un modelo ni que ya se haya demostrado una asociación con el bienestar. El uso posterior de cada variable dependerá de su pertinencia y de la calidad observada.

Se conservaron 12 variables complementarias para contextualizar las comparaciones: edad (p4), sexo asignado al nacer (p1), género declarado (p3), nivel educacional (p5), región (region), estado conyugal (p7), ingreso relativo respecto de la pareja (p92), año de inicio de convivencia (p84), edad de la pareja (p91), actividad sexual con la pareja en el último mes (p96), salud general percibida (p10) y calidad de vida percibida (p8).

Las cuatro variables auxiliares son «Tiene pareja actualmente» (p81), «Convive actualmente con su pareja» (p83), el identificador de encuesta (folio_encuesta) y la fecha registrada en la base (fecha). Las dos primeras determinan la población; el folio permite comprobar registros y vincularlos con el original; fecha se conserva para revisar una posible referencia temporal, sin asumir que representa el día de la entrevista.

En F2 se calculó la diferencia de edad como la edad de la persona encuestada (p4) menos la edad de su pareja (p91), con resultado para las 8.579 personas. Se reservó una segunda columna, años_convivencia_aprox, que permanece sin valores porque no se pudo validar el evento representado por fecha. Por ello, el CSV principal tiene 21 columnas: 19 originales preparadas, una derivada calculada y otra reservada. Las 8.579 ausencias de esta última son técnicas y no corresponden a no respuestas de la encuesta.

Las preguntas, respuestas posibles y códigos de ausencia están descritos en el [diccionario de datos](#). La [justificación de las 19 columnas](#) explica individualmente su utilidad y el dato o pregunta que representa.

El proyecto tiene un alcance descriptivo y comparativo, sin ponderación muestral. Se buscarán distribuciones, diferencias y patrones entre grupos, sin atribuir causalidad ni representatividad poblacional a estos resultados. Tampoco se pretende utilizar todas las columnas disponibles en ENSSEX ni incorporar necesariamente todas las complementarias en un único análisis. Esta delimitación respeta la distinción del manual entre describir la muestra y realizar estimaciones mediante factores de expansión (Ministerio de Salud, 2022).

Restricciones del análisis

Las variables son autorreportadas y reflejan la percepción de las personas al responder. Pueden verse afectadas por el recuerdo, la interpretación de las preguntas, la disposición a responder y la sensibilidad de los temas. Los resultados deben interpretarse dentro de estas limitaciones.

La disponibilidad de respuestas cambia según las variables requeridas. F2 conservó las 8.579 personas y registró 8.392 con información completa en las tres variables centrales; para dependencia económica y vida sexual hay 8.399 casos disponibles y para dependencia económica y bienestar mental o emocional hay 8.491. Estos denominadores deberán declararse en cada comparación. La conservación de faltantes evita atribuir respuestas no observadas, pero no elimina el posible sesgo de no respuesta.

Supuestos relevantes

Para el desarrollo e interpretación del proyecto se establecen los siguientes supuestos:

- El significado, tipo y codificación de cada variable se interpretan a partir del cuestionario, el libro de códigos y los metadatos del SAV. Las discrepancias entre fuentes se documentan antes de recodificar. Un número puede representar una categoría válida o una no respuesta según la pregunta; no se aplican reemplazos generales de códigos.
- La delimitación depende de que las respuestas sobre pareja actual y convivencia identifiquen adecuadamente la situación declarada por cada persona. El filtro se aplica mediante código y se comprueban sus conteos y condiciones, sin seleccionar filas o columnas manualmente.
- No se supone que las ausencias sean aleatorias. Se distinguen las preguntas no aplicables, la no respuesta codificada y las ausencias técnicas introducidas por una variable derivada no calculada. En esta fase se conservaron las respuestas ausentes sin imputarlas; las comparaciones posteriores deberán considerar su distribución y los casos disponibles.
- Se asumirá que las escalas ordinales utilizadas conservan un orden interpretable entre sus categorías, pero no necesariamente que la distancia entre niveles consecutivos sea equivalente. Esta consideración será especialmente relevante para las variables centrales del estudio y deberá ser respetada al seleccionar las técnicas descriptivas, comparativas o analíticas utilizadas en fases posteriores.
- Las conclusiones se limitarán a los patrones observados en esta muestra y a las variables y técnicas utilizadas, sin extrapolar los resultados a la población chilena.

3. Aplicación de herramientas científicas y reproducibilidad técnica

En esta sección se presentan las principales herramientas utilizadas para desarrollar el proyecto de manera ordenada, reproducible y trazable. Se describe el uso del ecosistema científico de Python, la configuración del entorno de trabajo y la gestión de dependencias. Asimismo, se incorpora el uso de Git, GitHub y Jupyter Notebook como apoyo para documentar y controlar el desarrollo del proyecto.

3.1 Herramientas científicas utilizadas

Se utilizó Python como lenguaje principal y Jupyter Notebook para reunir código, explicaciones y resultados. pandas permitió leer, seleccionar y transformar tablas; NumPy apoyó las operaciones numéricas y las comprobaciones vectorizadas dentro de las funciones del proyecto. La estructura de arrays y las operaciones por elemento descritas en la documentación de NumPy respaldan este uso (NumPy Developers, s. f.). Las herramientas se incorporaron por su función en el procesamiento y no como una lista de técnicas que debían aplicarse necesariamente.

Algunos ejemplos concretos de funciones en el proyecto son:

- Archivo ENSSEX original → `cargar_base()` → lectura y validación de estructura e integridad → DataFrame completo verificado.
- Dataset ENSSEX original → `seleccionar_convivientes()` → aplicación de filtros `p81 = 1` y `p83 = 1` → población de 8.579 personas que conviven con su pareja.

La organización funcional del proyecto permite asociar cada etapa del procesamiento con una entrada, una operación específica y un resultado verificable. Por ejemplo, `cargar_base()` controla la lectura e integridad del conjunto original y `seleccionar_convivientes()` aplica de manera reproducible las reglas que delimitan la población de estudio. Esta estructura evita repetir instrucciones aisladas en distintas celdas y facilita la reutilización, validación y trazabilidad del flujo de procesamiento.

3.2 Entorno reproducible y dependencias

Configuración del ambiente virtual

Se configuró un entorno virtual exclusivo, `.venv`, asociado al repositorio. Cada equipo lo reconstruye a partir de las versiones fijadas, de modo que la ejecución no dependa de librerías instaladas globalmente. El kernel Python (grupo9-mcdi500) utiliza el intérprete de ese entorno. Esta organización sigue el procedimiento docente de configuración y comprobación del ecosistema científico (Universidad Andrés Bello, 2026).

Registro de dependencias

Tabla 1. Herramientas y versiones del entorno verificado

Herramienta	Versión	Uso en el proyecto
Python	3.13.15, 64 bits	Ejecución del proyecto.
Git para Windows	2.55.0.windows.5	Control de versiones y Git Bash.
pip	26.2.1	Instalación y comprobación de dependencias.
NumPy	2.5.3	Operaciones numéricas.
pandas	3.0.5	Lectura y procesamiento tabular.
pyreadstat	1.3.6	Lectura del SAV y sus metadatos para la conversión.
SciPy	1.18.1	Herramientas científicas, según necesidad.
Matplotlib	3.11.2	Gráficos.
seaborn	0.13.2	Visualización estadística.
scikit-learn	1.9.1	Herramientas disponibles para fases posteriores, su instalación no implica que se entrene un modelo.
JupyterLab	4.6.3	Trabajo con notebooks.
ipykernel	7.3.0	Conexión entre Jupyter y el entorno del proyecto.

Las 121 dependencias están fijadas en requirements.txt. La tabla resume las principales; instalar una librería no implica haber aplicado todas sus técnicas. Python y Git se instalan por separado. pip se registra como herramienta de instalación y comprobación del entorno.

La instalación verificada corresponde a Windows de 64 bits e incluye dependencias específicas de ese sistema, como pywinpty. La evidencia de reproducción se limita a este entorno; no se presenta como una comprobación de instalación en otros sistemas operativos.

Rutas y portabilidad del proyecto

Las rutas se expresan respecto de la raíz del repositorio o se calculan desde la ubicación del notebook. Ambos cuadernos leen la misma base completa en F1/data/raw y F2 escribe sus resultados en F1/data/processed. F1 y F2 comparten también las funciones de F1/src. La ubicación dentro de F1 es una convención de organización del proyecto y no limita el uso de esos recursos a esa fase.

Verificación de la ejecución

F1 y F2 se ejecutaron completos desde kernels nuevos, con 10 y 13 celdas de código respectivamente, sin errores y con numeración consecutiva. Además, se comprobó el procedimiento

desde una copia nueva de GitHub, con un entorno virtual nuevo y una descarga de la fuente oficial. Las 121 dependencias coincidieron con las versiones fijadas. Los dos CSV regenerados coincidieron con los publicados al normalizar exclusivamente los saltos de línea CRLF a LF para la comparación de huellas.

La reproducción integral quedó registrada sobre la revisión d9de7f0 y publicada en el commit 3e162f7. La ejecución de F2 en el segundo equipo está documentada en d9de7f0. La comprobación de dependencias mediante pip check no detectó conflictos; la relectura de los CSV verificó todos sus valores y ausencias.

Se declara SEMILLA = 42 como convención para futuras operaciones aleatorias. La lectura, los filtros y las validaciones actuales de F1 y F2 son deterministas y no utilizan aleatoriedad; por ello, sus resultados no dependen del valor elegido como semilla.

Esta verificación es relevante porque disponer de un notebook no garantiza que pueda reproducirse. Samuel y Mietchen (2024) identificaron problemas de dependencias y de ejecución al volver a correr notebooks publicados. En este proyecto, la instalación nueva y la ejecución desde kernels reiniciados permiten comprobar que el flujo no depende del estado acumulado de una sesión.

Evidencia: [Instalación y ejecución](#) · [Reproducción integral](#) · [Ejecución en segundo equipo](#)

Al clonar el repositorio se descargan los dos CSV procesados, el diccionario y el esquema de variables. El SAV original, el CSV completo y sus metadatos están excluidos de Git. Se obtienen desde la raíz del repositorio, con el entorno activo, mediante el procedimiento siguiente:

```
python F1/src/convertir_enssex.py --download
```

Evidencia: [Obtención y conversión de ENSSEX](#)

3.3 Control de versiones y repositorio GitHub

El proyecto fue gestionado mediante Git y GitHub desde sus etapas iniciales, con el propósito de mantener un registro trazable de los cambios realizados y facilitar el trabajo colaborativo del equipo. Cada integrante configuró su identidad de Git y realizó sus propias contribuciones al repositorio, permitiendo identificar la autoría y evolución de los distintos componentes del proyecto. La distinción entre archivos de trabajo, cambios preparados y commits, junto con las instrucciones de colaboración y mensajes descriptivos, sigue la guía de Git y GitHub del curso (Universidad Andrés Bello, 2026).

La estructura siguiente muestra las carpetas y los archivos principales desde la raíz del repositorio. F3 y F4 se conservan como espacios para la continuidad del proyecto.

Figura 1. Organización del repositorio y recursos compartidos

proyecto-enssex/	
F1/	
data/raw/	Originales y conversión completa
data/processed/	Dos CSV generados por F2
docs/	Instalación, conversión y evidencias
notebooks/	F1_Definicion.ipynb
src/	Funciones compartidas y pruebas
F2/	
docs/	Diccionario, esquema y bitácora
notebooks/	F2_limpieza_transformacion_ENSSEX.ipynb
F3/ y F4/	
docs/	Continuidad del proyecto
README.md	Mapa conceptual y vinculación
requirements.txt	Descripción y ejecución
.gitignore	Dependencias con versiones
	Exclusiones de control de versiones

Convención de commits

Tabla 2. Convención de mensajes de commit

Prefijo	Uso
feat:	Incorporación de una nueva funcionalidad
fix:	Corrección de errores
docs:	Cambios en documentación
data:	Incorporación o ajuste relacionado con datos

- Ejemplos reales de commits utilizados:
 - docs: organiza las carpetas y actualiza la documentación del proyecto
 - feat: iniciar notebook F1 con definición y comprobación del entorno
 - feat: completar F2 con limpieza, transformación y validación documentadas

Ramas y pull requests

Durante las etapas iniciales del proyecto, el trabajo se ha gestionado principalmente sobre la rama principal del repositorio, dado que las tareas desarrolladas hasta el momento se han ejecutado de manera coordinada y sin requerir modificaciones simultáneas sobre los mismos componentes. No obstante, para las siguientes etapas se proyecta incorporar el uso de ramas específicas para aquellas tareas que se desarrollen en paralelo, con el propósito de aislar los cambios y evitar interferencias entre los integrantes del equipo. Una vez finalizado y verificado cada desarrollo, los cambios serán integrados a la rama principal mediante pull requests, permitiendo revisar previamente las modificaciones y mantener la trazabilidad del proceso de integración.

Contribuciones individuales y trazabilidad

El historial identifica contribuciones de ambos integrantes y permite reconstruir el avance. Karla inició F1 (915c30c), inició F2 (1cbf284) y registró su ejecución en el segundo equipo (d9de7f0). Guillermo completó F1 (5185d2e), amplió la selección a 19 columnas (f6e89b9), completó F2 (a2719e7), incorporó los CSV procesados (f374a0f), documentó la reproducción integral (3e162f7) y publicó el mapa actualizado (eebfe4b).

<https://github.com/gosoriozamora/mcdi500-grupo9-enssex/commits/main/>

3.4 Documentación y trazabilidad del proceso

El desarrollo del proyecto se documentó de manera progresiva a través de los notebooks correspondientes a las Fases 1 y 2, registrando no solo las operaciones realizadas, sino también los criterios utilizados para adoptar cada decisión técnica. Cada etapa relevante incorpora celdas narrativas que explican su propósito, funciones que implementan el procesamiento y resultados intermedios que permiten verificar el impacto de las decisiones adoptadas. Esta estructura busca mantener correspondencia entre lo descrito en el informe, lo ejecutado en los notebooks y los archivos generados en el repositorio.

En la Fase 1 se estableció como principio preservar íntegramente la base original y realizar únicamente su reconocimiento inicial. Se verificó un conjunto de 20.392 registros y 1.126 columnas, sin filas duplicadas ni folios ausentes o repetidos. Asimismo, se confirmó la presencia de las 19 variables seleccionadas para el proyecto, manteniendo el archivo original sin modificaciones. Esta fase permitió documentar la estructura, tipos de lectura, códigos especiales y supuestos necesarios antes de comenzar cualquier limpieza o transformación.

Durante la Fase 2, las decisiones de preparación se adoptaron después de realizar diagnósticos sobre los datos. La población de análisis se delimitó aplicando conjuntamente las condiciones $p81 = 1$, correspondiente a personas que declaran tener pareja, y $p83 = 1$, correspondiente a quienes conviven con ella. De los 20.392 registros originales, 11.239 correspondían a personas con pareja y finalmente 8.579 personas cumplieron ambas condiciones, constituyendo la población de trabajo.

La limpieza distinguió entre valores físicamente ausentes y códigos especiales de no respuesta definidos para cada pregunta. Como resultado, 883 celdas correspondientes a códigos NS/NR fueron recodificadas como valores ausentes, sin eliminar registros ni realizar imputaciones. La decisión de conservar los valores faltantes se tomó después de comparar distintas alternativas. Exigir respuestas completas en las 19 variables habría reducido la base de 8.579 a 7.825 personas, eliminando casos que aún contienen información válida para determinadas comparaciones. Por esta razón, se optó por conservar la totalidad de la población seleccionada y utilizar posteriormente denominadores específicos según las variables requeridas en cada análisis.

Se evaluaron cuatro variables mediante la regla de 1,5 veces el rango intercuartílico. Se obtuvieron 510 señales en total: una en la edad de la persona encuestada, ninguna en la edad de la pareja, siete en el año de inicio de convivencia y 502 en la diferencia de edad. La suma cuenta señales por variable y no necesariamente personas distintas. Se conservaron los valores porque el criterio estadístico no basta para concluir que son errores; su influencia podrá revisarse en el análisis posterior.

Las transformaciones fueron definidas según la naturaleza de cada variable. Las variables ordinales conservaron un orden explícito de categorías, mientras que las variables nominales fueron tratadas como categorías sin orden. Además, se generó una matriz auxiliar mediante codificación one-hot para las variables nominales, conservando separadamente el conjunto principal de datos interpretables. No se aplicó escalamiento a las edades ni a la diferencia de edad, debido a que en esta fase no se utiliza ningún algoritmo basado en distancias que lo requiera.

Como parte de las variables derivadas, se calculó la diferencia de edad entre la persona encuestada y su pareja para los 8.579 registros. En cambio, se descartó temporalmente el cálculo de los años de convivencia, dado que no fue posible verificar con suficiente certeza qué evento representa la variable fecha dentro de la base. En lugar de asumir una referencia temporal no documentada, se mantuvo la variable derivada reservada y sin valores hasta contar con respaldo suficiente. Esta decisión constituye un ejemplo de un enfoque evaluado, pero no implementado por falta de evidencia metodológica.

Finalmente, la trazabilidad técnica se verificó mediante pruebas sobre el conjunto real y casos controlados. El notebook F2 comprobó 130 invariantes del dataset y ejecutó satisfactoriamente 21 casos normales, límite y de excepción, incluyendo categorías fuera de dominio, tipos inesperados, fechas imposibles, columnas ausentes, folios repetidos y variables sin valores faltantes. También se verificó que el archivo original y las copias utilizadas para diagnóstico permanecieran intactos después del procesamiento.

La bitácora registra para cada decisión su motivo, la alternativa descartada y su impacto cuantificado. Se genera desde el mismo flujo que produce los datos procesados, lo que permite contrastar las cifras del informe con las salidas del notebook y reduce las inconsistencias de transcripción. El diccionario conserva el significado de preguntas, categorías, códigos originales y variables derivadas.

A continuación, enlace de notebooks donde se puede ver la evidencia técnica para cada fase:

[Notebook F1 de definición y reconocimiento inicial](#)

[Notebook F2 de limpieza y transformación](#)

Evidencia: [Bitácora de decisiones](#) · [Diccionario](#) · [Resultados de preparación](#)

4. Diseño de la solución y procesamiento de datos

La Fase 2 se estructuró mediante un pipeline reproducible de procesamiento de datos, diseñado para transformar el conjunto original de ENSSEX 2022–2023 en una base preparada para las etapas analíticas posteriores. El flujo se organizó de manera secuencial en cinco etapas: obtención y carga de los datos, exploración y diagnóstico inicial, limpieza, transformación y validación. Esta organización permitió verificar los datos antes de modificarlos y mantener una correspondencia clara entre las entradas, las decisiones adoptadas y los resultados obtenidos.

El archivo original y su conversión completa se conservan en `F1/data/raw`. La selección, limpieza y transformación se ejecutan sobre copias; los resultados verificados se exportan a `F1/data/processed`. Estas rutas corresponden a la convención compartida por F1 y F2 y permiten reconstruir el procesamiento sin editar manualmente la base. La separación entre originales y procesados responde a la organización requerida en la guía docente (Universidad Andrés Bello, s. f.).

El procesamiento siguió el principio de medir antes de decidir. Por esta razón, las decisiones sobre selección de registros, tratamiento de respuestas no válidas, valores faltantes, valores extremos, tipos de datos y transformaciones fueron adoptadas después de realizar un diagnóstico de las características observadas en el conjunto.

El flujo parte de la base completa y delimita la población de personas que tienen pareja y conviven con ella. Sobre las 19 columnas seleccionadas se limpian los códigos de no respuesta, se asignan tipos, se calculan las derivadas justificadas y se validan las salidas. En este contexto, limpiar o normalizar códigos significa homogeneizar su representación; no significa escalar las variables numéricas.

4.1 Codificación funcional

El procesamiento de los datos fue estructurado mediante funciones con responsabilidades específicas, evitando concentrar todas las operaciones en una secuencia única de instrucciones dentro del notebook. Esta organización permite separar las etapas de carga, selección, limpieza, transformación y validación, facilitando la reutilización del código y la verificación independiente de cada proceso.

Las principales operaciones de la Fase 2 se encuentran implementadas mediante funciones reutilizables en el módulo de preparación de datos y son ejecutadas desde el notebook siguiendo el orden definido por el pipeline. Cada función recibe parámetros asociados a la información que debe procesar, realiza una tarea delimitada y devuelve un resultado que puede ser comprobado antes de continuar con la etapa siguiente.

Las funciones se integran de manera secuencial. `cargar_base()` lee y comprueba el original; `seleccionar_convivientes()` devuelve una copia con los filtros y las columnas acordadas; `limpiar_codigos()` interpreta las no respuestas por pregunta; `construir_derivadas()` calcula la diferencia de edad; `tipificar_categorias()` y `codificar_nominales()` preparan las categorías; `validar_resultado()` y `exportar_resultados()` comprueban y guardan las salidas.

Pipeline

Base original → carga y comprobación → selección de convivientes → limpieza de códigos → transformación → validación → exportación

El siguiente fragmento de `seleccionar_convivientes()` muestra el paso central de la selección. Las columnas se obtienen del esquema declarado y los filtros se combinan antes de crear una copia. La función completa también comprueba columnas, folios y selección no vacía, y devuelve los conteos de cada filtro.

```
columnas = [v['nombre'] for v in esquema['variables']]
validar_columnas(base, columnas)
# Conservar solo personas que tienen pareja y conviven con ella.
con_pareja = base['p81'].eq(1)
convive = con_pareja & base['p83'].eq(1)
# Trabajar sobre una copia preserva la tabla original.
seleccion = base.loc[convive, columnas].copy()
```

Evidencia: [Funciones completas de preparación](#)

4.2 Preprocesamiento y transformación del dataset

El preprocesamiento se realizó a partir de un diagnóstico previo del conjunto de datos, evitando aplicar transformaciones de forma automática o únicamente por estar contempladas en la rúbrica. Se evaluaron las dimensiones, tipos de variables, valores faltantes, duplicados, códigos especiales de respuesta y posibles valores atípicos antes de definir cada tratamiento. Posteriormente, se compararon distintas alternativas para los valores faltantes y se aplicaron transformaciones acordes con la naturaleza nominal, ordinal o cuantitativa de cada variable. Este procedimiento responde a los criterios establecidos para la Fase 2, que exigen justificar cada transformación a partir de evidencia previa.

Diagnóstico inicial y selección de la población

La base original de ENSSEX 2022–2023 contiene 20.392 registros y 1.126 columnas. Antes de realizar cualquier transformación se comprobó su integridad, identificándose 0 filas idénticas duplicadas, 0 folios ausentes y 0 folios repetidos adicionales. Posteriormente, la población de estudio fue delimitada aplicando conjuntamente las condiciones $p81 = 1$, correspondiente a personas que declaran tener pareja, y $p83 = 1$, correspondiente a quienes conviven actualmente con ella. Este procedimiento redujo la población desde 20.392 registros a 8.579 personas, sobre las cuales se desarrolló el procesamiento posterior.

El diagnóstico de las 19 columnas originales incluyó tipos, categorías, campos vacíos y códigos especiales. En las 8.579 personas seleccionadas se observaron cero campos físicamente vacíos antes de la limpieza. La interpretación por pregunta evita confundir un código numérico válido con una no respuesta (Ministerio de Salud, 2022).

Los saltos del cuestionario determinan cuándo una pregunta es aplicable. La convivencia ($p83$), el ingreso relativo ($p92$), la dependencia económica ($p93$) y la actividad sexual con la pareja ($p96$) se preguntan a quienes tienen pareja; el año de inicio de convivencia ($p84$) se consulta cuando existe convivencia. El filtro conjunto $p81=1$ y $p83=1$ satisface estas condiciones. Los vacíos de personas

fuera de aplicación no se rellenan ni se clasifican todos como estructurales por su frecuencia (Ministerio de Salud, s. f.-a, pp. 22–24).

Limpieza y tratamiento de valores faltantes

Se recodificaron 883 celdas con códigos de no respuesta, incluidos desconocimiento, negativa o preferencia por no responder según la pregunta. Estos códigos se transformaron en valores ausentes sin eliminar personas ni imputar respuestas. El reconocimiento de ausencias y el uso de tipos que las admiten se apoyan en la documentación de pandas (The pandas development team, s. f.-c).

Para decidir el tratamiento de los valores faltantes se compararon distintas estrategias: conservar las ausencias, trabajar con casos disponibles para cada análisis, imputar mediante la media global, imputar mediante la mediana global y, para las variables de valoración, imputar mediante la mediana dentro de cada grupo de dependencia económica. La comparación consideró el número de valores modificados, la generación de valores fraccionarios y el cambio producido sobre la variabilidad de cada variable.

Tabla 3. Sensibilidad de los códigos de las variables centrales ante alternativas de imputación

Variable	Faltantes	Media global	Mediana global	Mediana por grupo
Dependencia económica p93	77	Reduce varianza 0,898% y genera 77 valores fraccionarios	Reduce varianza 0,186%	No corresponde
Vida sexual i_6_p9	105	Reduce varianza 1,224% y genera 105 valores fraccionarios	Reduce varianza 1,158%	Reduce varianza 1,136%
Bienestar emocional i_2_p9	11	Reduce varianza 0,128% y genera 11 valores fraccionarios	Reduce varianza 0,119%	Reduce varianza 0,119%

Nota. Comparación realizada sobre copias. La varianza corresponde a los códigos numéricos y se usa como diagnóstico mecánico de sensibilidad; no supone distancias iguales entre categorías ordinales ni constituye un resultado sustantivo de bienestar. No se aplicó ninguna de estas imputaciones a la base final.

A partir de esta comparación se decidió no imputar los valores faltantes. La imputación mediante la media fue descartada porque, además de reducir la variabilidad observada, generaba valores fraccionarios que no corresponden a las categorías discretas de las escalas ordinales. Las alternativas basadas en mediana evitaban este problema, pero igualmente reducían la variabilidad y concentraban artificialmente las respuestas. Se optó, por tanto, por conservar las ausencias y utilizar los casos disponibles según cada análisis posterior.

Esta decisión permitió mantener las 8.579 personas seleccionadas. Para las tres variables centrales existen 8.392 registros con información conjunta completa, mientras que exigir información completa en las 19 variables originales habría reducido el conjunto a 7.825 personas, excluyendo 754 casos aun cuando algunas de esas variables podrían no participar en un análisis determinado.

Valores atípicos y transformaciones

Para las variables cuantitativas se utilizó la regla de 1,5 veces el rango intercuartílico (IQR) como mecanismo de diagnóstico de posibles valores extremos. Se identificó una señal en la edad de la persona encuestada, siete en el año de inicio de convivencia y 502 en la diferencia de edad con la pareja, mientras que la edad de la pareja no presentó observaciones señaladas por este criterio. Estas observaciones fueron interpretadas como señales de revisión estadística y no automáticamente como errores.

En consecuencia, no se eliminaron valores extremos, ya que una observación poco frecuente — como una elevada diferencia de edad o un inicio antiguo de convivencia— puede corresponder a una situación real. Su eventual influencia deberá ser evaluada en las fases analíticas posteriores.

Las variables fueron transformadas de acuerdo con su rol analítico. Las variables cuantitativas se almacenaron en tipos numéricos que admiten valores ausentes, mientras que las variables categóricas se diferenciaron entre ordinales y nominales. Las cinco variables ordinales — dependencia económica (p93), valoración de la vida sexual (i_6_p9), bienestar emocional (i_2_p9), salud general (p10) y calidad de vida (p8)— recibieron un orden explícitamente declarado, evitando que dicho orden fuera determinado automáticamente por la librería. La declaración de categorías y de su orden sigue el comportamiento documentado por pandas (The pandas development team, s. f.-a).

En dependencia económica (p93), los códigos 1 a 3 avanzan desde mayor a menor dependencia; en las valoraciones, un código mayor expresa una valoración más favorable. Las nominales se conservaron sin orden. Como representación auxiliar, siete nominales complementarias se codificaron mediante one-hot, con indicador de ausencia: sexo asignado al nacer (p1), género (p3), educación (p5), región (region), estado conyugal (p7), ingreso relativo (p92) y actividad sexual reciente (p96). La matriz tiene 8.579 filas y 65 columnas: el folio y 64 indicadores. La función `get_dummies` permite declarar ese indicador de ausencia (The pandas development team, s. f.-b).

No se aplicó escalamiento ni normalización a las variables cuantitativas en esta fase. Las edades y la diferencia de edad se mantienen expresadas en años y actualmente no se implementa un modelo basado en distancias u otro procedimiento que requiera que las variables se encuentren en una escala común. En caso de que una técnica posterior requiera escalamiento, este deberá justificarse según el método seleccionado y realizarse en la etapa correspondiente.

Como transformación adicional se calculó la **diferencia de edad con la pareja** como la edad de la persona encuestada menos la edad de su pareja, obteniéndose valores para las 8.579 observaciones. En cambio, se decidió no calcular los años aproximados de convivencia, debido a que no se logró validar suficientemente qué referencia temporal representa la variable fecha. Esta columna derivada se mantiene reservada con valores ausentes, evitando construir información a partir de un supuesto no confirmado.

Resultado del preprocesamiento

Como resultado del pipeline se obtuvo un conjunto principal de 8.579 filas y 21 columnas, compuesto por las 19 variables originales preparadas, la diferencia de edad calculada y una columna

reservada para la duración aproximada de convivencia. Paralelamente, se generó una matriz auxiliar de variables nominales codificadas mediante one-hot de 8.579 filas y 65 columnas.

El conjunto resultante fue sometido a comprobaciones de dominios, tipos de datos, categorías, valores faltantes, orden de variables ordinales, integridad de folios y correspondencia de las transformaciones con los datos originales. La validación técnica detallada se presenta en el apartado 4.3. Los archivos procesados fueron exportados y posteriormente releídos para comprobar que la escritura no modificara los valores ni las ausencias registradas.

4.3 Validación técnica y verificación

La validación técnica se realizó en distintas etapas del pipeline con el propósito de comprobar que las reglas de selección, limpieza y transformación produjeran los resultados esperados sin modificar involuntariamente los datos originales. Para ello se combinaron comprobaciones sobre el conjunto real de ENSSEX, casos de prueba controlados y verificaciones mediante “assert”, manteniendo visibles las salidas obtenidas en el notebook.

Validación del conjunto procesado

Una vez finalizadas las etapas de limpieza y transformación, se ejecutó una validación integral del conjunto resultante mediante la función `validar_resultado()`. Esta comprobación evaluó aspectos relacionados con la cantidad y orden de los registros, presencia y unicidad de los folios, cumplimiento de los filtros de población, dominios permitidos, tipos de datos, orden de las categorías ordinales, ubicación de los valores faltantes, construcción de la diferencia de edad y correspondencia de las variables nominales codificadas mediante one-hot.

En total se comprobaron 130 invariantes sobre el conjunto real, todas con resultado satisfactorio. Entre las verificaciones realizadas se comprobó que se conservaran las 8.579 personas seleccionadas, que estuvieran presentes las 19 columnas originales y los dos espacios destinados a variables derivadas, que los folios permanecieran presentes y únicos y que todos los registros cumplieran simultáneamente las condiciones definidas para tener pareja y convivir con ella.

Casos normales, límite y excepciones

Además de comprobar el conjunto real, se construyeron casos pequeños en memoria para evaluar el comportamiento de las funciones frente a situaciones normales, casos límite y entradas incorrectas. Estas pruebas fueron realizadas independientemente del dataset ENSSEX, por lo que no modificaron los datos originales.

Los casos normales permitieron comprobar que las funciones conservaran correctamente respuestas válidas que podrían confundirse con códigos especiales. Por ejemplo, se verificó que los códigos 8 y 9 fueran aceptados como regiones válidas cuando corresponden a categorías documentadas, que el código 8 permaneciera válido para estado civil y que los extremos 1 y 7 fueran aceptados correctamente en las escalas de valoración.

Los casos límite incluyeron situaciones como una variable con una única categoría, sin valores faltantes y con varianza cero, así como una columna completamente ausente. También se verificó

que el procesamiento mantuviera correctamente el significado de las categorías, los valores ausentes y las variables codificadas mediante one-hot.

Por último, las pruebas de excepción comprobaron que el sistema detectara entradas incompatibles con las reglas del proyecto, entre ellas categorías fuera del dominio permitido, texto introducido en una variable de edad, valores fraccionarios en variables que requieren enteros, fechas imposibles, tablas vacías, columnas ausentes, nombres de columnas duplicados, folios repetidos y selecciones sin personas convivientes. Un error esperado se consideró correctamente detectado únicamente cuando se obtuvo el tipo de excepción y mensaje definidos; cualquier fallo no previsto habría detenido la ejecución del notebook.

Se ejecutaron 21 casos controlados, todos con resultado satisfactorio. La tabla siguiente presenta una selección ilustrativa; el registro completo se conserva en la validación de F2 y en el módulo de pruebas.

Tabla 4. Ejemplos de los casos controlados ejecutados

Tipo de prueba	Ejemplo	Resultado
Normal	Región 8 y 9 reconocidas como categorías válidas	OK
Normal	Escala ordinal acepta valores extremos 1 y 7	OK
Límite	Variable con una sola categoría y varianza cero	OK
Límite	Columna completamente ausente	OK
Excepción	Código fuera del dominio permitido	Detectado
Excepción	Texto inesperado en variable edad	Detectado
Excepción	Edad con valor fraccionario	Detectado
Excepción	Fecha imposible	Detectada
Excepción	Folios duplicados	Detectados
Excepción	Columna obligatoria ausente	Detectada
Total en el registro completo		21

Evidencia: [Los 21 casos y sus resultados](#) · [Código de las pruebas](#)

Protección de los datos originales

La validación también contempló comprobaciones explícitas destinadas a asegurar que las transformaciones no alteraran involuntariamente las fuentes de datos. Para ello se utilizaron instrucciones “assert” que comparan la huella de la base completa y de la selección original antes y después del procesamiento, además de verificar nuevamente la huella SHA-256 del archivo fuente.

```
assert prep.huella_tabla(datos) == huella_inicial
assert prep.huella_tabla(seleccion) == huella_seleccion
assert prep.sha256_archivo(RUTA_DATOS) == identidad_inicial
```

Estas comprobaciones permiten detener la ejecución en el punto donde se detecte una alteración no prevista, en lugar de descubrir la inconsistencia en una etapa posterior del pipeline. El resultado obtenido confirmó que el archivo original y las copias utilizadas para el diagnóstico permanecieron intactos.

Comprobación de resultados intermedios y exportación

Durante todo el procesamiento se conservaron salidas visibles que permiten verificar la evolución del conjunto de datos, incluyendo los conteos antes y después de la selección de población, el diagnóstico de valores faltantes, las alternativas de imputación evaluadas, la revisión de valores extremos, el perfil de tipos y ausencias del conjunto final y los resultados de las pruebas técnicas.

Al finalizar el pipeline se generaron dos archivos procesados: el conjunto principal de 8.579 filas y 21 columnas y una matriz auxiliar de variables nominales de 8.579 filas y 65 columnas. Tras la exportación, los archivos fueron nuevamente leídos y comparados con las estructuras mantenidas en memoria para comprobar que el proceso de escritura no alterara valores ni ausencias. La verificación de relectura obtuvo resultado satisfactorio.

Finalmente, el notebook genera un resumen y una bitácora que registran las principales decisiones, sus efectos cuantitativos, las validaciones ejecutadas y los archivos exportados. De esta forma, la evidencia de verificación queda asociada directamente al mismo flujo que produce los datos procesados y puede ser rastreada desde el notebook hasta los archivos generados y el repositorio del proyecto.

5. Notebook F1 de definición del proyecto

5.1 Contenido y alcance

F1_Definicion.ipynb presenta la procedencia de ENSSEX, la pregunta, los objetivos, el alcance descriptivo, los supuestos y la selección de 19 columnas. Incluye el significado de las variables y su función para las comparaciones posteriores. La definición coincide con el apartado 2 del informe.

El código comprueba el entorno, las 121 dependencias, la estructura del repositorio y la identidad y lectura del CSV completo. Después reconoce sus 20.392 registros y 1.126 columnas y muestra el perfil de las variables seleccionadas. En esta fase no se filtra la base, no se recodifican respuestas y no se calculan derivadas: el reconocimiento conserva el conjunto original.

5.2 Ejecución y evidencias

El cuaderno conserva 10 celdas de código ejecutadas consecutivamente y sin errores. Las comprobaciones finales verifican entorno, estructura, lectura e identidad del CSV, presencia de las 19 columnas, detección de entradas incorrectas e integridad del archivo y de la tabla en memoria. Sus explicaciones y salidas se mantienen visibles para permitir la revisión del proceso.

La reproducción desde una copia y un entorno nuevos confirmó su ejecución independiente. Este resultado cumple el alcance de definición y configuración exigido para F1 sin anticipar el procesamiento de F2 (Universidad Andrés Bello, s. f.).

Evidencia: [Notebook F1 ejecutado](#) · [Documentación F1](#) · [Reproducción integral](#)

6. Notebook F2 de limpieza y transformación

6.1 Organización del cuaderno

F2_limpieza_transformacion_ENSSEX.ipynb desarrolla el flujo obtención → exploración → limpieza → transformación → validación. Cada etapa contiene una explicación previa, llamadas a funciones reutilizables y resultados visibles. El cuaderno justifica por qué se conserva cada columna e identifica su nombre comprensible junto al código de la encuesta.

La carga comprueba la conversión íntegra del SAV antes de seleccionar personas o columnas. Los diagnósticos preceden a las decisiones sobre no respuesta, tipos y extremos. Las alternativas de imputación se evalúan sobre copias; la base final conserva las ausencias y las personas seleccionadas. La tipificación, las derivadas y la matriz nominal se generan mediante funciones de F1/src, sin edición manual de datos.

6.2 Ejecución y resultados

El notebook conserva 13 celdas de código ejecutadas en orden y sin errores. El cierre registra siete comprobaciones satisfactorias: entorno y correspondencia con F1; selección y conservación de personas; códigos y categorías; casos normales, límites y excepciones; exportación y relectura; bitácora y diccionario; e integridad del original.

El resultado es una base principal de 8.579×21 y una matriz nominal de 8.579×65 . Se recodificaron 883 celdas de no respuesta; no se imputaron respuestas ni se eliminaron personas por faltantes o extremos. Las 130 invariantes y los 21 casos controlados se describen en el apartado 4.3. La ejecución fue comprobada en ambos equipos y mediante una reproducción integral desde una copia nueva.

6.3 Archivos que recibe la fase siguiente

Los CSV `enssex_convivientes_F2.csv` y `enssex_convivientes_F2_nominales.csv` están publicados en F1/data/processed. El diccionario y esquema de F2/docs documentan los tipos, categorías y códigos necesarios para interpretarlos al volver a leerlos. F3 podrá utilizar estos archivos como entrada, declarar los denominadores de cada comparación y evaluar la influencia de los extremos. La columna reservada de duración no debe incluirse en una eliminación global de casos incompletos.

Evidencia: [Notebook F2 ejecutado](#) · [Documentación F2](#) · [Validación](#) · [Diccionario](#)

7. Vinculación del mapa conceptual con el avance

El mapa actualizado conserva las seis etapas y los dos retornos iterativos de la planificación inicial. Distingue lo implementado en F1 y F2 de lo proyectado para F3 y F4, e incorpora las variables que sostienen la pregunta, el entorno virtual y los conectores entre cada etapa y las evidencias de reproducibilidad, trazabilidad y documentación. La leyenda explica los colores y las flechas; la versión de la Formativa 1 se conserva como antecedente.

Evidencia: [Mapa conceptual actualizado en PDF](#) · [Mapa editable](#) · [Correspondencia completa y evolución](#)

La tabla relaciona los elementos del mapa con archivos y resultados concretos. Los enlaces permiten localizar la evidencia en el repositorio y distinguir una implementación comprobada de una decisión futura. Esta correspondencia responde al criterio de vinculación de la guía docente (Universidad Andrés Bello, s. f.).

Tabla 5. Correspondencia entre los elementos del mapa y su implementación

Elemento del mapa	Estado	Evidencia y alcance
Problemática y alcance	Implementado F1	Pregunta y alcance descriptivo sin ponderación Ver evidencia
Dataset y fuente	Implementado	SAV identificado y conversión completa verificada Ver evidencia
Indicadores centrales	Implementado	Dependencia económica, vida sexual y bienestar emocional Ver evidencia
Población y columnas	Implementado F2	Filtros conjuntos y selección de 19 columnas mediante código Ver evidencia
Reconocimiento inicial	Implementado F1	20.392 × 1.126; original intacto Ver evidencia
Adquisición y carga	Implementado	Descarga, conversión y huellas del original Ver evidencia
Exploración de calidad	Implementado F2	Tipos, ausencias, dominios, duplicados y extremos Ver evidencia
Faltantes y saltos	Implementado F2	Condiciones de aplicación; 883 recodificaciones; 0 imputaciones Ver evidencia

Elemento del mapa	Estado	Evidencia y alcance
Transformaciones	Implementado F2	Tipos, categorías y diferencia de edad calculada Ver evidencia
Duración de convivencia	Condicionada	Columna sin valores hasta validar la referencia temporal Ver evidencia
Representación nominal	Implementado F2	64 indicadores y un folio, en archivo separado Ver evidencia
Validación y exportación	Implementado F2	130 invariantes, 21 casos y relectura de CSV Ver evidencia
Análisis por grupos	Proyectado F3	Comparaciones de cada valoración según dependencia Ver evidencia
Interpretación y comunicación	Proyectado F4	Conclusiones, limitaciones y comunicación de resultados Ver evidencia
Exploración → definición	Retorno representado	Revisión de pregunta y selección según calidad y pertinencia Ver evidencia
Evaluación → preparación	Retorno proyectado	Revisar decisiones y repetir validación si la evidencia lo exige Ver evidencia
Python, pandas y NumPy	Implementado	Funciones de procesamiento y comprobaciones Ver evidencia
Jupyter y notebooks	Implementado	Explicaciones, código y salidas en F1 y F2 Ver evidencia
Entorno y versiones	Implementado	Python 3.13.15, .venv y 121 dependencias fijadas Ver evidencia
Git y GitHub	Implementado	Commits y aportes de ambos integrantes Ver evidencia
Reproducibilidad	Comprobada	Copia y entorno nuevos; archivos regenerados coincidentes Ver evidencia

Elemento del mapa	Estado	Evidencia y alcance
Trazabilidad	Implementado	Folios, huellas, commits y registro de decisiones Ver evidencia
Documentación	Implementado	Narrativas, motivos, alternativas e impactos medidos Ver evidencia
Arquitectura compartida	Implementado	F1/data/raw, F1/data/processed y F1/src para ambas fases Ver evidencia
Archivos de gobierno	Implementado	README, requirements y .gitignore con sus funciones Ver evidencia

La planificación evolucionó desde una pregunta amplia sobre bienestar y calidad de vida hacia la comparación de dos valoraciones según dependencia económica entre convivientes. La calidad de vida quedó como complementaria. La selección de 19 columnas se justificó por su función y se implementó mediante código. Se mantuvo la decisión de regenerar el CSV desde el SAV tras los problemas de lectura iniciales, y se añadieron controles de integridad para poder reconstruir ese paso.

La preparación confirmó que convenía conservar las ausencias y revisar los extremos sin eliminarlos automáticamente. También mostró un límite concreto: la duración de convivencia no podía calcularse con una referencia temporal no validada. El mapa incorpora estas decisiones y conecta cada principio con sus evidencias: el commit identifica el cambio, la celda narrativa y la bitácora explican el motivo, y el README permite reconstruir el entorno y el procedimiento. Los retornos iterativos mantienen abierta la revisión de decisiones cuando avance el análisis.

8. Conclusiones del avance F1 y F2

El desarrollo de las Fases 1 y 2 permitió establecer una base técnica y metodológica sólida para la continuidad del proyecto. En la Fase 1 se delimitó la problemática de investigación, se definieron la población y las variables relevantes, y se configuró un entorno reproducible mediante Python, Jupyter, un ambiente virtual y dependencias versionadas. Además, se estructuró el repositorio y se documentaron las condiciones necesarias para ejecutar el proyecto de manera consistente.

En la Fase 2 se obtuvo, exploró, limpió, transformó y validó el conjunto de datos de ENSSEX 2022–2023. A partir de los 20.392 registros originales se delimitó una población de estudio de 8.579 personas que tienen pareja y conviven con ella, conservando 19 variables originales y generando una variable derivada de diferencia de edad. El proceso incluyó la recodificación de 883 respuestas especiales como valores ausentes, sin aplicar imputaciones ni eliminar casos por faltantes, y se verificó mediante 130 invariantes y 21 casos de prueba, permitiendo obtener un conjunto procesado y técnicamente validado para su uso posterior.

Entre las principales limitaciones identificadas se encuentra la presencia de respuestas faltantes o codificadas especialmente, la naturaleza autorreportada de las variables y la imposibilidad de construir de manera confiable la duración de convivencia, debido a que no se logró validar suficientemente la referencia temporal asociada a la variable fecha. Asimismo, el alcance actual es descriptivo y comparativo, sin ponderación muestral ni atribución de relaciones causales.

El resultado deja disponible una base procesada, documentada y verificada para la Fase 3. En esa etapa se desarrollarán las comparaciones asociadas a la pregunta, con denominadores específicos y revisión de la influencia de los extremos. La Fase 4 integrará la interpretación y comunicación de resultados. Este avance establece las condiciones para responder la pregunta posteriormente, tal como exige la continuidad entre fases prevista en la guía (Universidad Andrés Bello, s. f.).

9. Bibliografía

- Ministerio de Salud. (s. f.-a). *Cuestionario de la Encuesta Nacional de Salud Sexualidad y Género 2022–2023*. <https://epi.minsal.cl/bases-de-datos/>
- Ministerio de Salud. (s. f.-b). *Encuesta Nacional de Salud Sexualidad y Género ENSSEX 2022–2023* [Conjunto de datos]. Portal de Datos Abiertos. <https://datos.gob.cl/dataset/encuesta-nacional-de-salud-sexualidad-y-genero-enssex-2022-2023>
- Ministerio de Salud. (2022). *Manual de uso de base de datos y libro de códigos de la Encuesta Nacional de Salud Sexualidad y Género 2022–2023*. <https://datos.gob.cl/dataset/encuesta-nacional-de-salud-sexualidad-y-genero-enssex-2022-2023/resource/e155a68f-13f4-48e0-81e0-123f5c23433f>
- NumPy Developers. (s. f.). *NumPy the absolute basics for beginners*. NumPy documentation. Recuperado el 20 de septiembre de 2026, de https://numpy.org/doc/stable/user/absolute_beginners.html
- Samuel, S., & Mietchen, D. (2024). Computational reproducibility of Jupyter notebooks from biomedical publications. *GigaScience*, 13, artículo giad113. <https://doi.org/10.1093/gigascience/giad113>
- The pandas development team. (s. f.-a). *Categorical data*. pandas documentation. Recuperado el 20 de septiembre de 2026, de https://pandas.pydata.org/docs/user_guide/categorical.html
- The pandas development team. (s. f.-b). *pandas.get_dummies*. pandas documentation. Recuperado el 20 de septiembre de 2026, de https://pandas.pydata.org/docs/reference/api/pandas.get_dummies.html
- The pandas development team. (s. f.-c). *Working with missing data*. pandas documentation. Recuperado el 20 de septiembre de 2026, de https://pandas.pydata.org/docs/user_guide/missing_data.html
- Universidad Andrés Bello. (s. f.). *Guía de desarrollo de la evaluación Sumativa 1 Fases 1 y 2* [Material docente de MCDI500 Programación para la Ciencia de Datos].
- Universidad Andrés Bello. (2026). *Guía de Git y GitHub* (versión para Windows) [Material docente de MCDI500 Programación para la Ciencia de Datos].